BIG-DATA

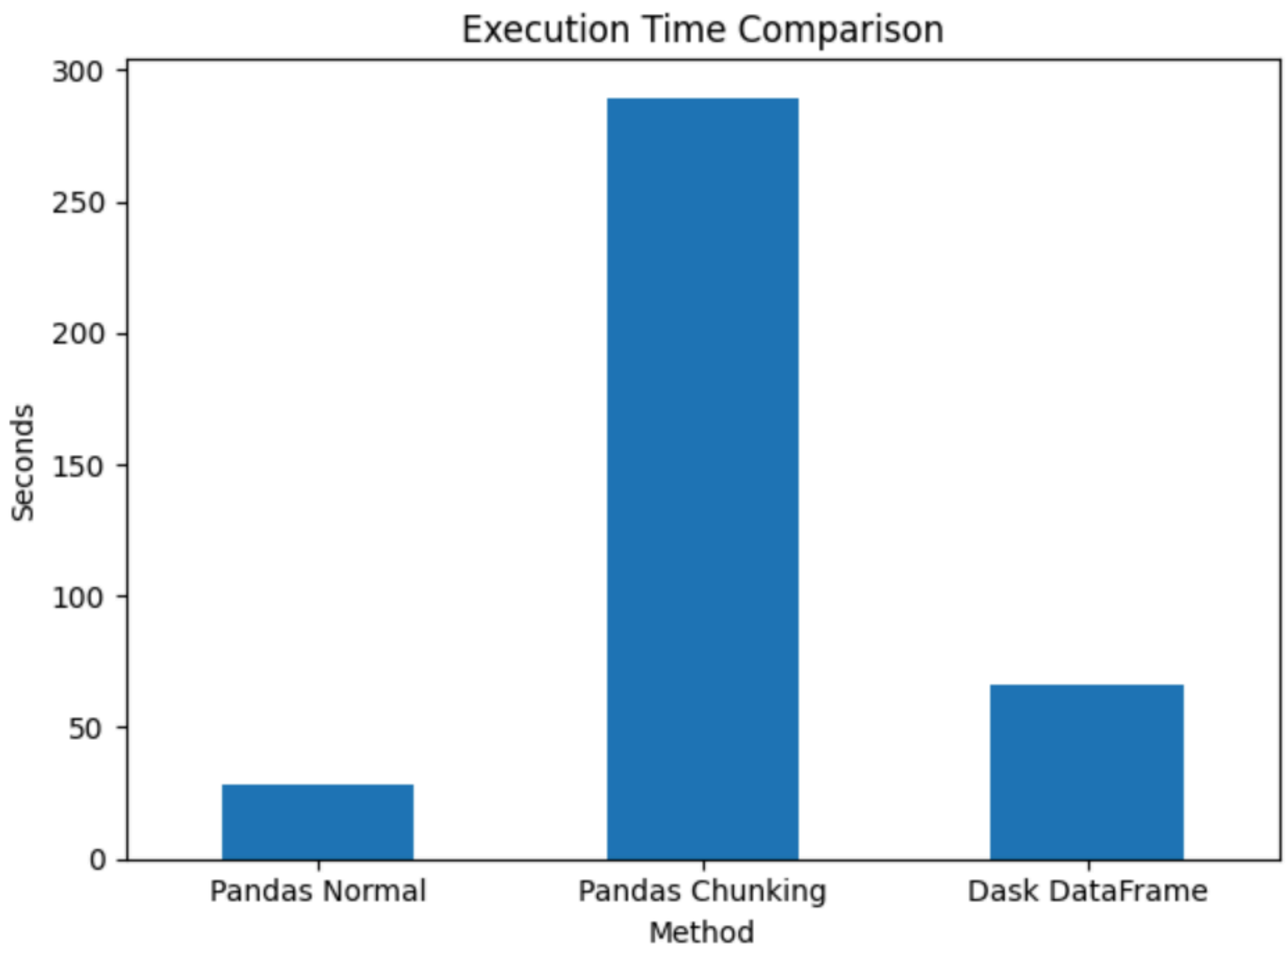
TP2

الطالبة :
فليون نور الهدى -IA-

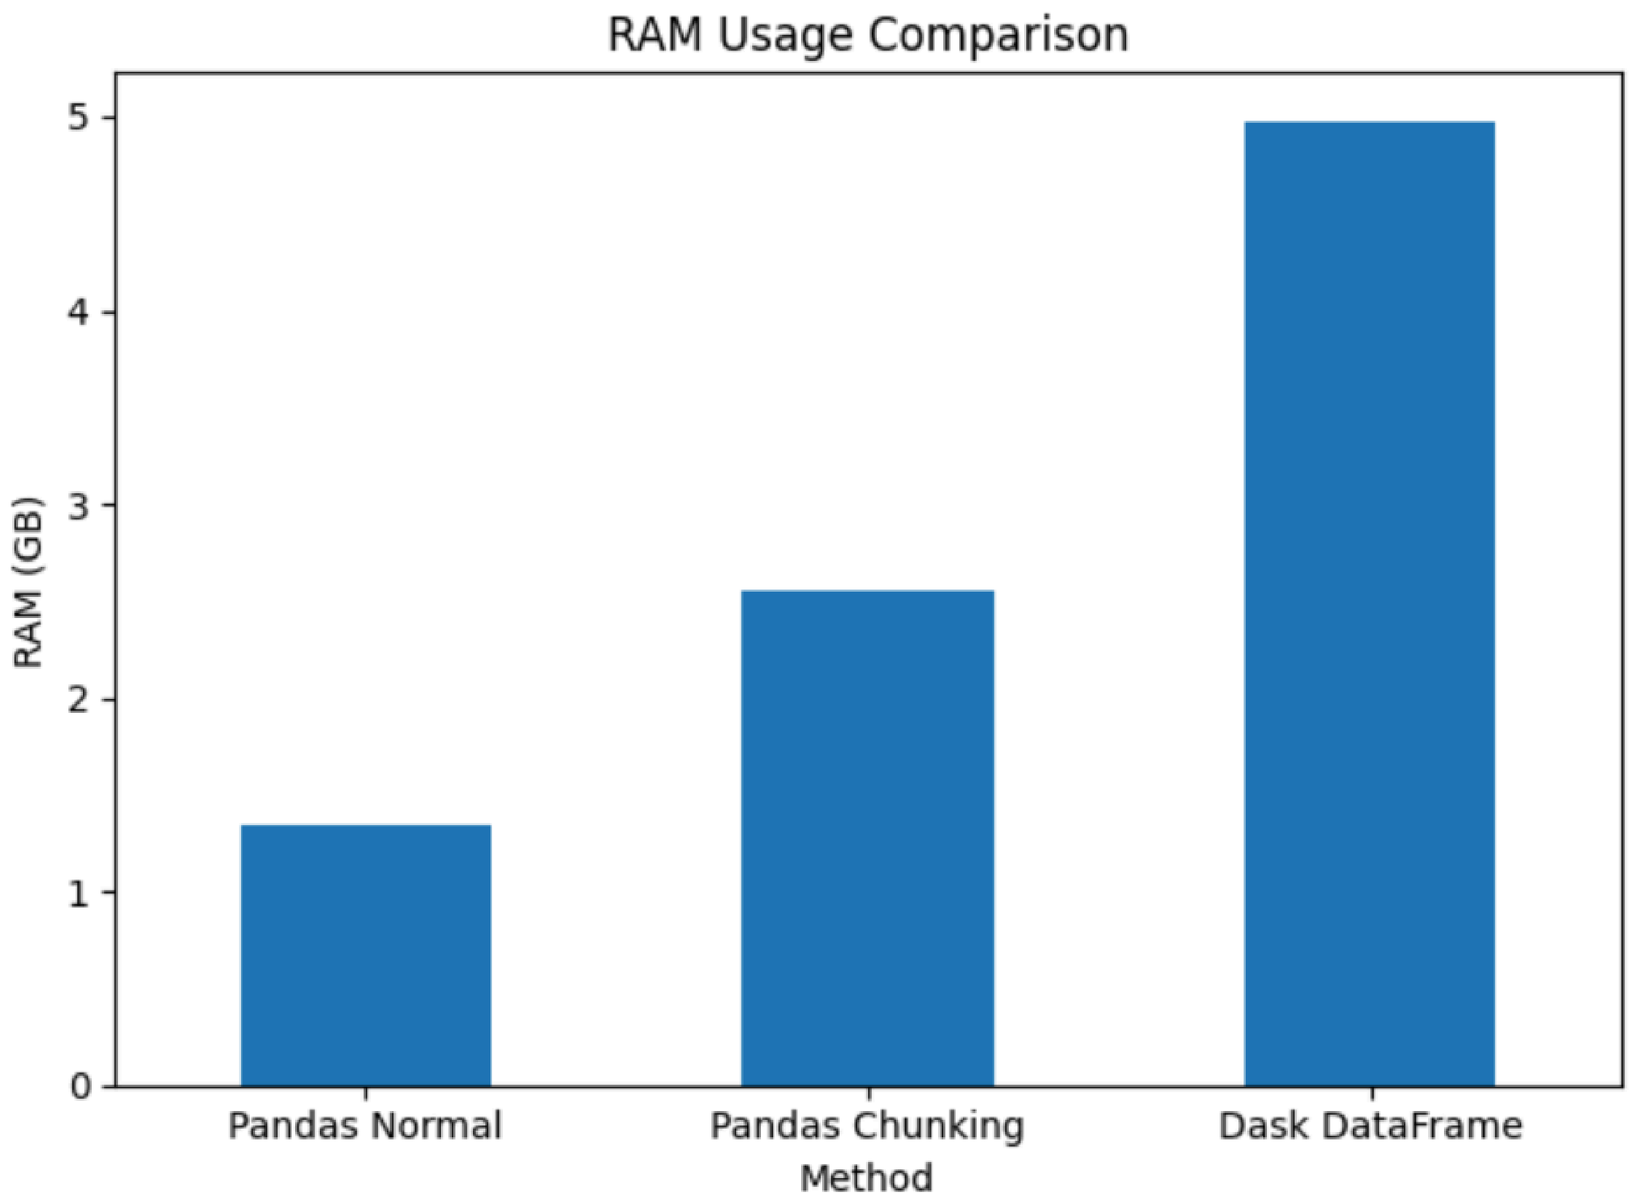
يتناول هذا المشروع تحليل بيانات الرحلات الجوية بهدف فهم تأخيرات الطائرات ودراسة أهم العوامل المرتبطة بها.

تعتمد الدراسة على ملفات بيانات الرحلات الجوية التي تغطي السنوات من 2009 إلى 2018

عدد الصفوف	حجم
61,56M	7,10GB



أظهرت النتائج أن Dask حققت زمن تنفيذ أقل من باقي الطرق باستخدام المعالجة على دفعات، اذ استغرقت 66.57 ثانية مقابل 289.45 ثانية. ويفسر هذا الأداء بقدرة Dask على تقسيم العمليات إلى مهام يمكن تنفيذها بالتوازي، مما يجعلها مناسبة لمعالجة كميات كبيرة من البيانات .اما تقنية Chunks فهي تقسيم ملف البيانات الكبير إلى أجزاء صغيرة، و معالجة كل جزء على حدة بدل تحميل الملف كاملا إلى ذاكرة RAM دفعة واحدة.



أظهرت نتائج المشروع اختلافا في استهلاك الذاكرة بين طرق معالجة البيانات الثلاث.
سجلت طريقة Pandas باستخدام المعالجة على دفعات (Chunks) أقصى استهلاك للذاكرة بلغ حوالي 2.549GB ، بينما بلغ استهلاك الذاكرة بعد تنفيذ المعالجة باستخدام Dask حوالي 4.977GB.
تشير هذه النتائج إلى أن Dask كانت أسرع في التنفيذ، لكنها لم تكن الأقل استهلاكا للذاكرة في هذه التجربة. ويحتمل أن يعود ذلك إلى تكاليف إدارة المهام والتوازي والبيانات الوسيطة. كما أن قياس الذاكرة بعد انتهاء التنفيذ في Dask يختلف عن قياس أقصى استهلاك أثناء التنفيذ في الطرق الأخرى.